

Upwork Portfolio

京东 vs 淘宝

iPhone 16 价格数据采集与对比分析

Web Scraping · Data Analysis · Price Intelligence · Anti-Anti-Scraping

 2026-05-12

 数据源: JD.com · Taobao.com

 Playwright + CDP + Chart.js

Web Scraping

Data Analysis

Price Intelligence

E-commerce

Anti-Anti-Scraping

CDP

Playwright

Python

1. 项目背景

客户需要获取京东（JD.com）和淘宝（Taobao.com）两大中国电商平台上 iPhone 16 系列手机的真实价格数据，并进行跨平台对比分析，为竞品定价策略提供数据支撑。

核心挑战

京东和淘宝是中国反爬防护最严格的电商平台，分别采用了多层反爬机制：

防护层	京东	淘宝
SPA 客户端渲染	✔ React SPA（仅 HTML 空壳）	✔ 动态加载
headless 浏览器检测	✔ Canvas/WebGL/UA 检测	✔ 反自动化检测
会话令牌指纹绑定	✔ _t cookie 绑定指纹+IP	✔ 登录态保护
API 签名保护	✔ h5st + x-api-eid-token	✔ 加密参数
频率限制	✔ 短时间多次请求触发拦截	✔ 滑块验证码
CSS 类名混淆	✔ CSS Modules 哈希类名	✔ 同

难度评级：★★★★★ — 京东与淘宝均为国内反爬最强电商平台之一

2. 技术方案

2.1 核心思路：真实浏览器 CDP 直连

传统方案（requests/headless Chrome/Cookie 注入）因京东的 _t 令牌指纹绑定机制全部失效。最终采用 Chrome DevTools Protocol（CDP）直连用户真实浏览器的方案：

```
用户真实 Chrome（完整指纹 + 登录态）
├── --remote-debugging-port=9222 启动调试模式
├── Playwright connect_over_cdp() 建立 CDP 连接
├── 复用 browser.contexts[0]（Cookie + 指纹天然继承）
├── 新标签页导航至搜索页
├── 等待 SPA 渲染完成
└── DOM 层面提取商品数据
```

2.2 技术栈

工具	用途
Playwright (Python)	CDP 连接 + 浏览器自动化控制
Python 3.12	数据采集脚本、清洗、分析
Chart.js	价格可视化（交互式图表）
Linux (Ubuntu/GNOME)	运行环境，DISPLAY=:1 X11
Chrome 148	带完整指纹的真实浏览器

2.3 爬取流程

```
# 1. 启动 Chrome (远程调试模式)
chrome --remote-debugging-port=9222 --user-data-dir=/tmp/profile

# 2. Playwright CDP 连接
browser = await playwright.chromium.connect_over_cdp("http://localhost:9222")
page = await browser.contexts[0].new_page()

# 3. 导航 + 等待 SPA 渲染
await page.goto(url, wait_until="domcontentloaded")
await page.wait_for_timeout(12000) # SPA 渲染等待

# 4. DOM 提取 (不依赖哈希类名)
products = await page.evaluate("""
    () => document.querySelectorAll('[data-sku]').map(card => ({
        sku: card.getAttribute('data-sku'),
        text: card.innerText.replace(/\\s+/g, ' ').trim()
    }))
""")
```

2.4 京东反爬攻破记录

反爬措施	尝试方案	结果
SPA 空壳	requests/httpx	✗ 仅 HTML 空壳
headless 检测	DrissionPage ChromiumPage	✗ 重定向登录页
headless 检测	Pydoll 纯异步 CDP	✗ 被检测
headless 检测	Camoufox 反指纹 Firefox	✗ 仍被检测
_t 令牌绑定	Cookie 注入新浏览器	✗ 令牌绑指纹
API 签名	直接调用搜索 API	✗ h5st 签名保护
真实 Chrome CDP 直连	Playwright connect_over_cdp	✓ 100% 成功

3. 数据采集结果

● 京东 JD.com 搜索关键词：iPhone16 总页数：42 页 原始数据：1,260 条商品 有效 iPhone 商品：266 条（经清洗，¥2,500+） 自营商品：10 条（Apple产品京东自营旗舰店） 价格区间：¥2,649 ~ ¥10,999 价格中位数：¥5,168 平均价格：¥5,343	● 淘宝 Taobao.com 搜索关键词：iPhone16 总页数：43 页 原始数据：2,022 条商品 有效 iPhone 商品：31 条（经清洗，¥2,500+） 价格区间：¥2,540 ~ ¥6,599 价格中位数：¥3,488 平均价格：¥3,874
---	---

3.3 数据清洗规则

清洗管线
1. 名称过滤：必须包含 16/iPhone/苹果
2. 价格过滤：¥2,500 ~ ¥15,000（排除配件）
3. 配件排除：壳、膜、充电、支架、线、保护
4. 模型分类：Pro Max / Pro / Plus / 标准版
5. 去重：根据标题 + 价格归一化去重

266 / 31 商品数 京东 / 淘宝	¥2,649 / ¥2,540 最低价 京东 / 淘宝	¥10,999 / ¥6,599 最高价 京东 / 淘宝	¥5,168 / ¥3,488 中位数 京东 / 淘宝
¥5,343 / ¥3,874 均价 京东 / 淘宝			


4. 数据可视化

价格分布曲线对比


京东红色 · 淘宝橙色 — X轴为按价格排序的商品序号



价格区间分布对比



各型号均价对比



价格区间分布明细


价格区间	京东	淘宝
¥2,500 – 3,500	43 件	16 件
¥3,500 – 4,500	62 件	8 件
¥4,500 – 5,500	45 件	3 件
¥5,500 – 6,500	49 件	3 件
¥6,500 – 8,000	49 件	1 件
¥8,000 – 11,000	18 件	0 件

各型号均价对比

型号	京东均价	淘宝均价	价格差
iPhone 16 标准版	~¥5,000	~¥3,500	~¥1,500
iPhone 16 Plus	~¥5,700	~¥4,000	~¥1,700
iPhone 16 Pro	~¥6,400	~¥5,000	~¥1,400
iPhone 16 Pro Max	~¥7,600	~¥6,500	~¥1,100



5. 对比分析结论



核心发现： 京东均价 **¥5,343** 高出淘宝 **¥3,874** 约 **38%**，但京东商品以国行全新正品为主，淘宝大量为卡贴机/美版/二手/翻新机。

结论

1. 京东价格真实反映国行正品市场价 — ¥5,000–11,000 区间合理
2. 淘宝价格低但商品质量参差不齐 — 大量为卡贴机/美版/二手/翻新机
3. 同等品质（国行全新正品）下，两平台价差约 10–15%，非表面上的 38%
4. 淘宝 ¥8,000 以上高端机型几乎为空白

6. 技术亮点

6.1 独创的 CDP 反反爬方案

解决了 **headless 检测 + 令牌指纹绑定 + SPA 渲染 + API 签名** 四层反爬，这套思路可复用于任何国内强反爬站点（京东、淘宝、拼多多、抖音电商等）。

6.2 全流程自动化

爬取 → 清洗 → 去重 → 分析 → 图表生成
全部脚本化，一键运行

6.3 数据质量保证


- 双重清洗管线（名称 + 价格 + 配件过滤）
- 标题归一化去重
- 多个价格字段交叉验证

6.4 可复用的技能包

建立完整的 `jd-price-scraper` 方案：

- 5 层爬取方案（`SessionPage` → `ChromiumPage` → `Camoufox` → `CDP` → `API`）
- 4 个参考文档（启动指南、Cookie 注入、比价模板、图表生成）
- 3 个可运行脚本（单页爬取、多页全量爬取、图表生成）

6.5 技能栈评估



7. 交付物

文件	说明
jd_cdp_scraper.py	京东 CDP 单页爬虫脚本
jd_multi_page_scraper.py	京东全量 42 页爬虫脚本
tb_scraper.py	淘宝全量爬虫脚本
jd_chart_generator.py	数据清洗 + Chart.js 图表生成
jd_vs_tb_comparison.html	京东 vs 淘宝对比可视化
jd_iphone16_price_chart.html	京东单站价格分析可视化
scraping_master.md	爬虫数据分析师知识库（12 模块）